

Geometría Proyectiva y Alineación


Visión Por Computadora
2026



Introducción

- **Meta:** Mapear el mundo 3D a 2D.
- **Problema:** La geometría euclidiana es insuficiente.
- **Herramienta:** Coordenadas Homogéneas y Matrices.
- **Modelo:** Cámara Pinhole (Intrínsecos/Extrínsecos).
- **Transformación:** Homografías y DLT.
- **Algoritmo:** Estimación robusta con RANSAC.
- **Aplicación:** Panoramas, SLAM, Realidad Aumentada.

El Desafío la Perspectiva



$$x' = Hx$$

El mundo es tridimensional, pero nuestros sensores son planos 2D. Para reconstruir la estructura o unir imágenes, necesitamos mapear puntos de un plano a otro matemáticamente.

El Problema Proyectivo


- La geometría euclidiana conserva longitudes y ángulos.
- Las cámaras **no** conservan estas propiedades.
- Las líneas paralelas convergen en puntos de fuga.
- Los objetos se hacen más pequeños a medida que se alejan.
- Necesitamos un nuevo marco matemático.
- La geometría proyectiva modela el proceso de obtención de imágenes.
- Maneja puntos en el infinito de forma natural.

El Espacio Proyectivo \mathbb{P}^2

- Punto Euclideo $(x, y) \in \mathbb{R}^2$.
- Punto Homogéneo $\mathbf{x} = \begin{bmatrix} 1 \\ x \\ y \\ w \end{bmatrix}^T \in \mathbb{P}^2$.
- Conversión: Dividir por $w \rightarrow \left(1/w, x/w, y/w \right)$.
- **Invariancia de Escala:** $\mathbf{x} \sim k\mathbf{x}$ para $k \neq 0$.
- **Puntos al Infinito:** Ocurren cuando $w = 0$.
- Permite representar transformaciones como matrices lineales.
- Simplifica: Proyección se vuelve multiplicación matricial.

El Lenguaje: Coordenadas Homogéneas

Euclidiano



Homogéneo

$$(x, y) \rightarrow \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- Añadimos una dimensión extra (factor de escala)
- $(x, y) \Rightarrow (x, y, 1)$
- Convierte divisiones en multiplicaciones de matrices
- Invarianza de escala:
 $k(x, y, w) \sim (x, y, w)$

Euclideanas vs Homogéneas

Euclidean

$$\mathbf{x}' = \mathbf{x} + \mathbf{t}$$

Non-Linear (Addition)

Homogeneous

$$(x, y) \rightarrow (x, y, 1)$$



$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

La Solución: Aumentar una dimensión
unifica rotación y traslación en una sola
operación: **Multiplicación de Matrices.**

Coordenadas Homogeneas


- Las coordenadas estándar 2D son (x, y) .
- Las escalas homogenas agregan escala: (x, y, w) .
- Se convierte al dividir: $(\frac{x}{w}, \frac{y}{w})$.
- Permite representar matrices de traslados
- Los puntos en el infinito tienen $w = 0$.
- Forma estándar: $\tilde{x} = [\quad, x, y, 1]^T$.
- Invariante de escala: $k[x, y, w] \equiv [x, y, w]$

Coordenadas Homogéneas: La clave Proyectiva



Añadimos una dimensión extra. Esto linealiza la proyección perspectiva y nos permite representar puntos en el infinito (donde $w=0$).

De la Geometría 3D a la Imagen Digital




Una exploración técnica del modelo de cámara estenopeica y la solución algebraica para la estimación de parámetros.

El Modelo Pinhole (Cámara Estenopeica)

- La forma más simple de capturar la realidad es la "Cámara Oscura". La luz pasa por un agujero minúsculo, proyectando una imagen invertida en el plano opuesto. Utilizamos la **regla de los triángulos semejantes** para modelar esto.

$$-\frac{x}{f} = \frac{X}{Z} \rightarrow x = -f \left(\frac{X}{Z} \right)$$


- El signo negativo indica la inversión de la imagen



Modelo de Cámara Pinhole

- La luz pasa a través de una pequeña abertura.
- Proyecta una imagen invertida sobre el plano del sensor.
- Mapea coordenadas de cámara 3D a pixeles.
- Ecuación:
 - $\mathbf{x} = K[R \mid t]\mathbf{X}$
 - $\mathbf{x} = K[I \mid \mathbf{0}]\mathbf{X}_{cam}$.
- **Intrínsecos (K):** Distancia focal y centro..
 - K describe las propiedades internas de la cámara.
- **Extrínsecos (R, t):** Rotación y traslación.
 - $[R|t]$ describe la posición de la cámara en el mundo.
- K es triangular superior de 3×3 .
- f_x, f_y :Distancia focal en unidades de pixel.
- (c_x, c_y) :Punto principal (centro óptico).
- s : Factor de "skew" (usualmente 0).
- Define la geometría interna del sensor.

Parámetros Extrínsecos (Posición y Orientación)



Definen **dónde** está la cámara.
6 Grados de Libertad.

- **Rotación** (R): Matriz 3×3 que alinea la orientación.
- **Traslación** (t): Vector 3×1 de posición.

Matriz Combinada: $[R \mid t]$

Parámetros Intrínsecos (La Matriz K)

The diagram shows the intrinsic camera matrix K as a 3x3 matrix. The first column contains f_x , 0, and 0. The second column contains s , f_y , and 0. The third column contains c_x , c_y , and 1. Brackets and lines connect these elements to their respective descriptions: f_x and f_y are grouped by a bracket labeled 'Distancia Focal (zoom/escala en píxeles)'; s is labeled 'Skew (sesgo de ejes)'; and c_x and c_y are grouped by a bracket labeled 'Punto Principal (centro óptico)'.

$$K = \begin{bmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

Distancia Focal (zoom/escala en píxeles)

Skew (sesgo de ejes)

Punto Principal (centro óptico)

Definen **cómo** la cámara forma la imagen.
Son parámetros internos de la lente y el sensor.


La Matriz de Proyección P

$$x = PX$$


$$P = \underbrace{K}_{\text{Intrínsecos}} \times \underbrace{[R \mid t]}_{\text{Extrínsecos}}$$

Una matriz de 3×4 que mapea directamente coordenadas homogéneas del mundo (X) a coordenadas homogéneas de imagen (x).

Parámetros Intrínsecos (La Matriz K)



Flujo de Transformación de Coordenadas



Transformaciones Planares

- **Traslación:** Mueve puntos y conserva la orientación.
- **Euclidiana:** Rotación + Traslación (Rígida).
- **Similitud:** Añade escala uniforme (conserva los ángulos).
- **Afín:** Las líneas paralelas permanecen paralelas.
- **Proyectiva (Homografía):** Las líneas rectas permanecen rectas.
- Proyectiva es la función lineal más general.
- Representada por matrices de 3×3 .

Transformaciones Proyectivas 2D

- **Isometría:** Rígida (Rotación + Traslación). 3 GDL.
- **Similitud:** Añade escala isotrópica. 4 GDL.
- **Afín:** Paralelismo conservado. 6 GDL.
- **Proyectiva (Homografía):** 8 GDL.
- Líneas rectas se mantienen rectas.
- Matriz H de 3×3 no singular.
- Fundamental para "Image Stitching" (Panoramas).


La Transformación Proyectiva (Homografía)

La Transformación Proyectiva (Homografía)

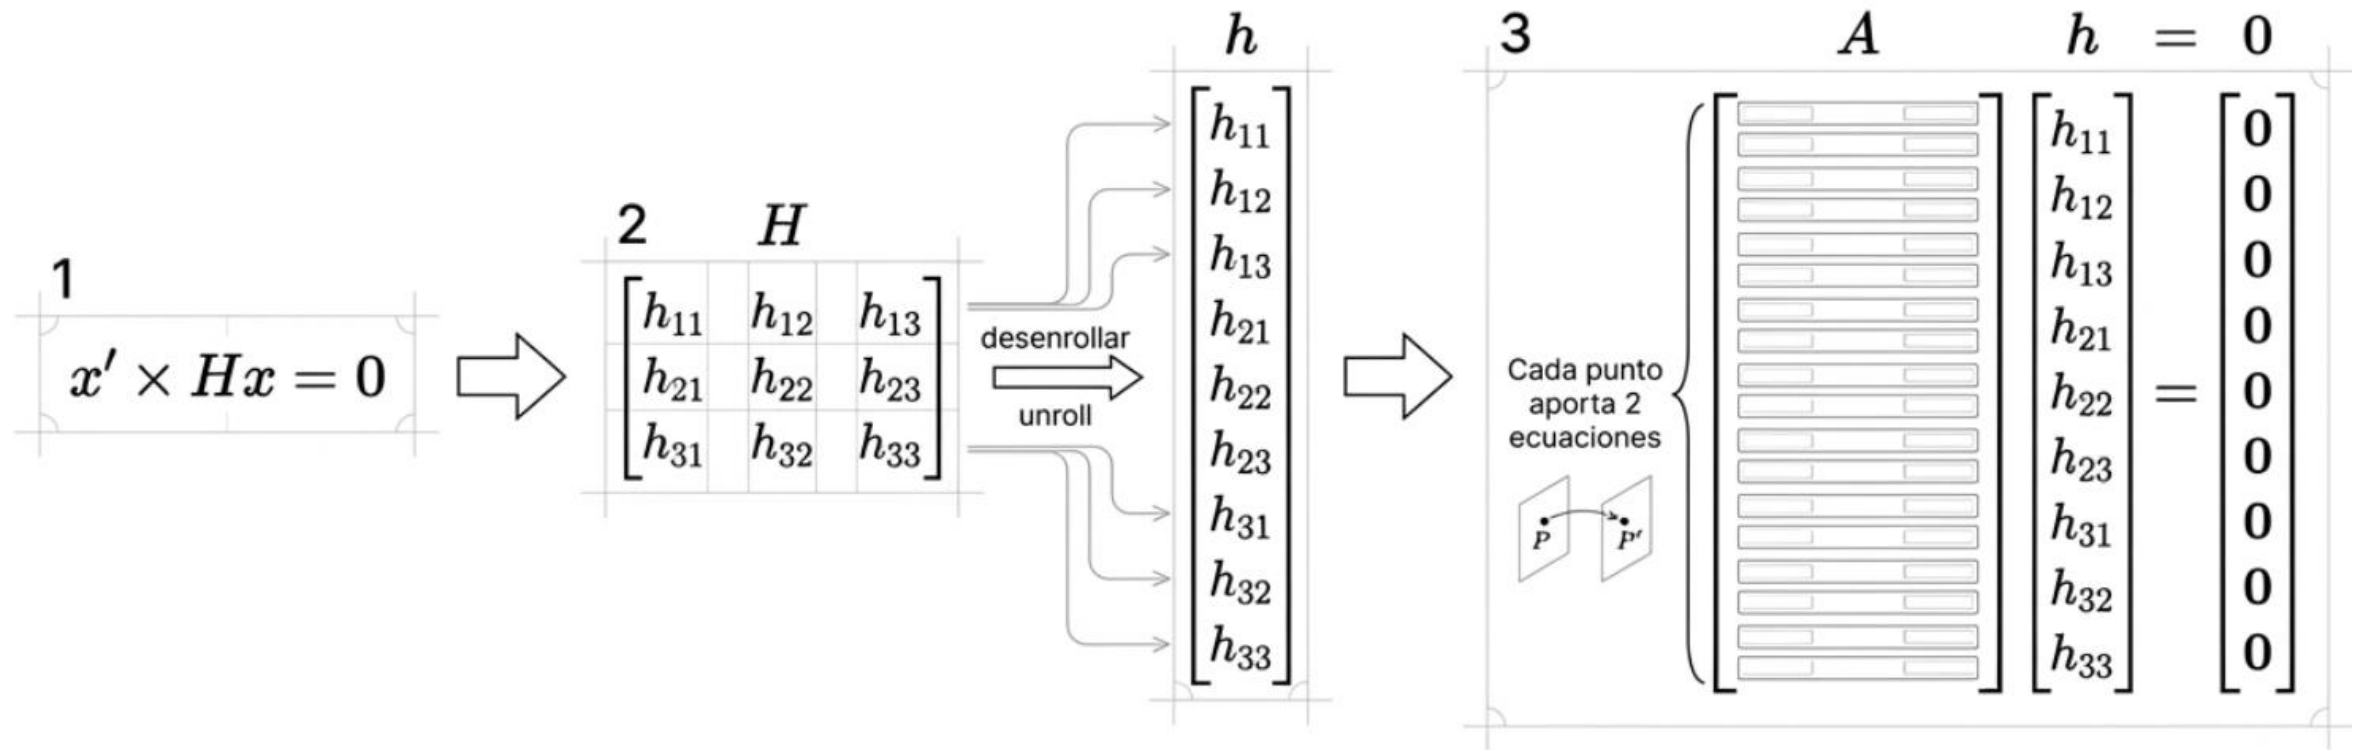
$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix}$$

La Homografía encapsula la relación geométrica entre dos planos proyectivos.

- 8 grados de libertad (escala ambigua)
- Preserva la colinealidad (líneas rectas)
- Permite rectificación y panoramas



DLT (Direct Linear Transformation)




Restricción: Mínimo 4 puntos correspondientes para resolver 8 incógnitas.

Resolviendo la Homografía (DLT)

- Objetivo: Hallar H tal que $\mathbf{x}'_i \times H\mathbf{x}_i = \mathbf{0}$.
 - H es una matriz de 3×3 no-singular, y tiene 8 grados de libertad
- Genera sistema lineal homogéneo $Ah = \mathbf{0}$.
- A es matriz $2N \times 9$ ($N \geq 4$ puntos).
- Solución trivial $h = 0$ no es útil.
- Restricción: Minimizar $\|Ah\|$ sujeto a $\|h\| = 1$.
- **Solución:** Vector singular de A asociado al menor valor singular.
- Se obtiene vía SVD (Singular Value Decomposition).

Singular Value Decomposition



El Motor del Cálculo: SVD (Singular Value Decomposition)

The diagram illustrates the Singular Value Decomposition (SVD) of a matrix A . Matrix A is shown on the left with dimensions $m \times n$. It is equal to the product of three matrices: U (dimensions $m \times m$), Σ (dimensions $m \times n$), and V^T (dimensions $n \times n$). The matrix V^T is highlighted in blue. The background features a faint image of a museum interior with a sign that says "Museum".

El problema $Ah=0$ tiene solución trivial $h=0$. Para evitarla, minimizamos $\|Ah\|$ sujeto a $\|h\|=1$.

Solución h = Vector singular derecho asociado al valor singular más pequeño


$$V^T = \begin{bmatrix} x_1 & \cdots & \cdots & x_1 \\ v_2 & \cdots & \cdots & v_2 \\ x_3 & \cdots & \cdots & x_4 \\ \vdots & \vdots & \vdots & \vdots \\ x_n & \cdots & \cdots & z_n \end{bmatrix}$$

Solución para h (Menor valor singular)


Pseudo Inversa y Mínimos Cuadrados

$$\tilde{\mathbf{X}} = \mathbf{A}^\dagger \mathbf{B}$$


$$\mathbf{A}^\dagger = \mathbf{V} \mathbf{\Sigma}^{-1} \mathbf{U}^T$$




Dado que \mathbf{A} no es cuadrada, no existe inversa. La Pseudoinversa encuentra la solución de **Mínimos Cuadrados** (Least Squares).



Normalizar los Datos




Normalización de Datos



Pasos de la Normalización:


1. Trasladar centroide al origen $(0,0)$
2. Escalar distancia promedio a $\sqrt{2}$
3. Calcular SVD
4. Des-normalizar ($H_{\text{final}} = T^{-1} H T$)




El Desafío de los "Outliers"

- Detectamos características (SIFT, ORB, Harris).
 - Emparejamiento de características (SIFT) genera errores
- Coincidimos descriptores entre dos imágenes.
- Las coincidencias contienen outliers (coincidencias erróneas).
 - **Outliers:** Emparejamientos falsos que no siguen el modelo.
- Mínimos Cuadrados (DLT) asume ruido Gaussiano en todo.
 - Trata de encajar todo
 - Un solo outlier desvía la solución enormemente.
- El promedio no es robusto ante valores extremos.
- Necesitamos un enfoque de "consenso/votación", no de promedio.
- Solución estándar en industria: **RANSAC**.

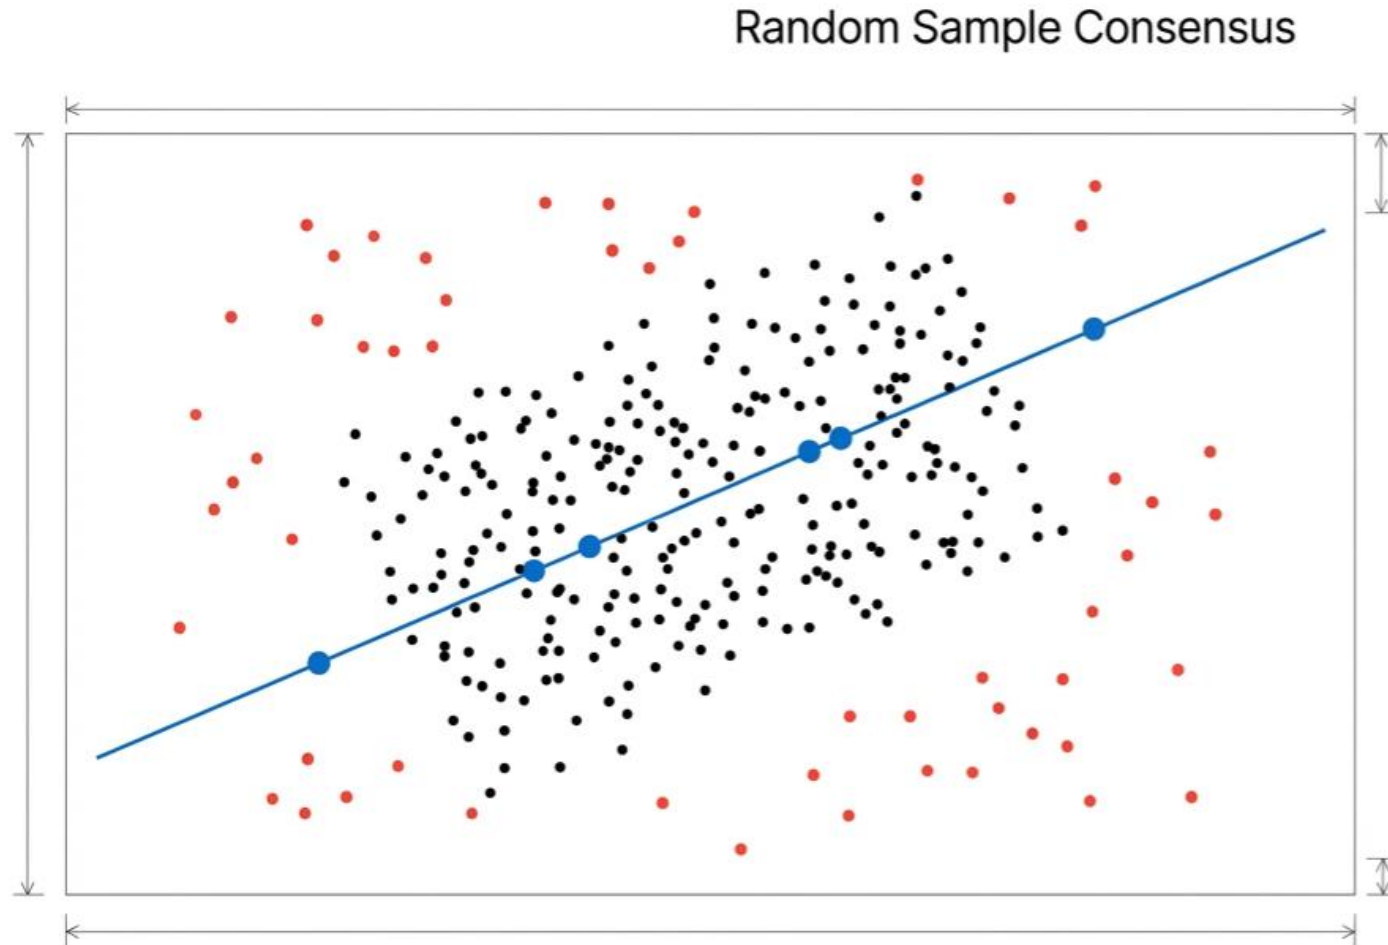
El desafío de los Outliers



- SVD asume error Gaussiano (ruido suave).
- Un solo emparejamiento incorrecto destruye la estimación.
- Mínimos Cuadrados intenta 'complacer' a todos los puntos, incluso los erróneos.



Defensa de RANSAC

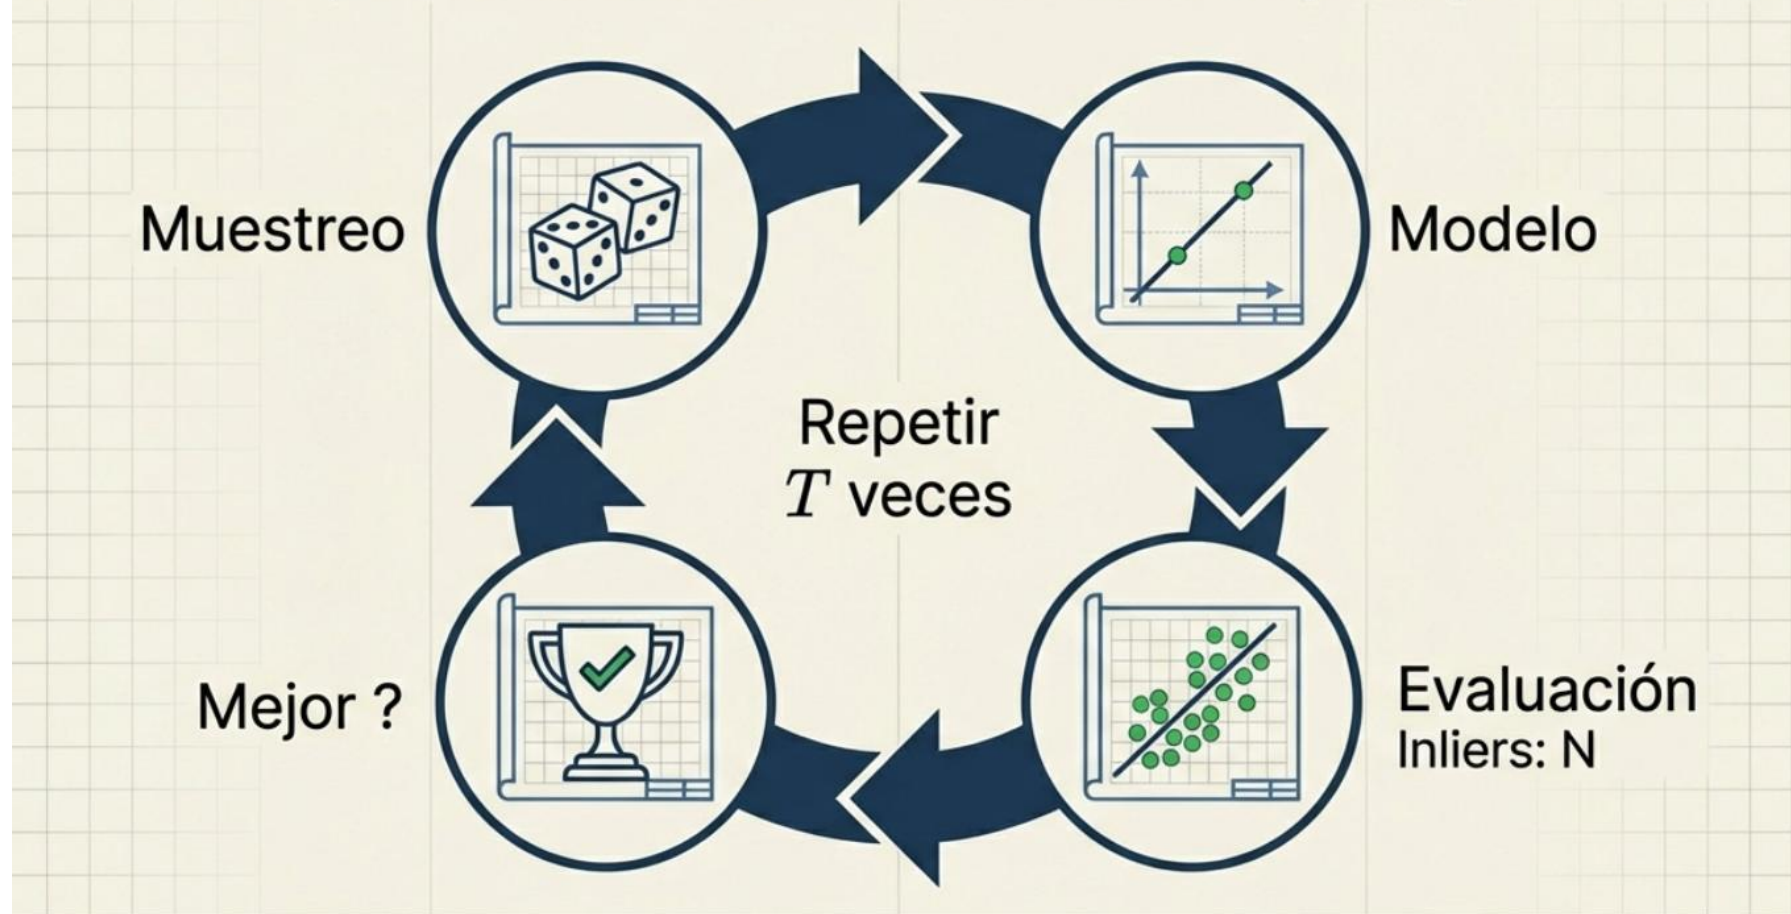


Un enfoque democrático:

1. Usar el mínimo de datos para una hipótesis (4 puntos).
2. Preguntar al resto: "¿Están de acuerdo?"
3. El modelo con más votos (inliers) gana.

Defensa de RANSAC


RANdom SAMple Consensus: Buscar el consenso de la mayoría, ignorar el ruido.



Algoritmo RANSAC

- **Paso 1:** Seleccionar s puntos aleatorios (mínimo 4).
- **Paso 2:** Calcular modelo hipotético H_{test} .
- **Paso 3:** Verificar cuántos puntos ajustan (Inliers).
- **Criterio:** Distancia $\| \mathbf{x}' - H_{test}\mathbf{x} \| < umbral$.
- **Paso 4:** Repetir N veces.
- **Paso 5:** Quedarse con el modelo con más Inliers o votos.
- **Paso 6:** Refinar con todos los inliers (SVD final).

Algoritmo de RANSAC en 4 Pasos Generales



Estrategia: Fuerza bruta inteligente

Probabilidad en RANSAC

- No iteramos infinitamente; calculamos el límite
- Fórmula: $N = \frac{\log(1-p)}{\log(1-(1-e)^s)}$.
- s :Puntos necesarios para el modelo (4 para Homografía).
- e : Proporción estimada de outliers (ej. 50%).
- p : Probabilidad de éxito deseada (ej. 0.99).
- Si $e = 50\%$ y $s = 4$, $N \approx 72$ iteraciones.
- Computacionalmente muy eficiente.

Detallando las Iteraciones (T)

The diagram shows the formula for the number of iterations T required for RANSAC to find a model with a given probability of success. The formula is:

$$T = \frac{\log(1-p)}{\log(1-(1-e)^s)}$$


Annotations with arrows pointing to the formula components:

- Probabilidad de Éxito (ej. 99%) points to p in the numerator.
- Proporción de Outliers points to e in the denominator.
- Puntos mínimos para el modelo points to s in the denominator.

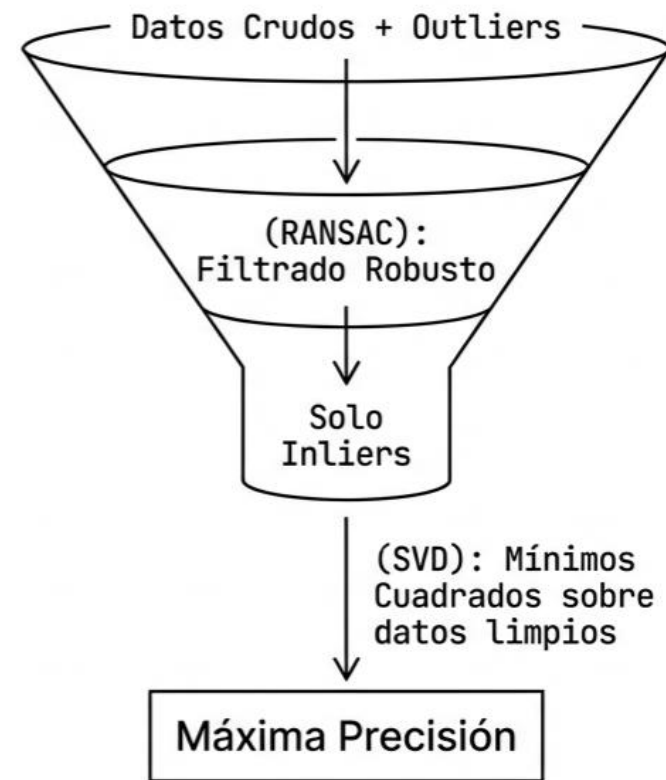
RANSAC garantiza matemáticamente el éxito incluso con datos altamente contaminados.

El Pipeline de Visión Computacional

- Visión por Computadora = Geometría + Álgebra Lineal + Estadística




Refinamiento Final




Del Caos a la Estructura


- La visión geométrica robusta no es solo calcular; es saber qué datos ignorar y cómo procesar óptimamente los que quedan



Aplicaciones Reales



Realidad Aumentada



Conducción Autónoma



- **AR/VR:** Inserción de objetos virtuales estables.



- **Robótica:** Estimación de distancias a obstáculos.



- **Reconstrucción 3D:** Modelado digital desde fotografías.

Resumen

- Pinhole → Homogéneas → Homografía → RANSAC.
- Las coordenadas homogéneas linealizan las matemáticas de proyección.
- Modelo estenopeico: $x=PX$
- (Intrínsecos/Extrínsecos).
- Las homografías mapean planos utilizando matrices 3×3 .
- Los datos del mundo real son ruidosos.
- RANSAC encuentra geometría a pesar de los valores atípicos significativos.
- La robustez (RANSAC) es más importante que la precisión pura.

¡Gracias!